

Análise Exploratória dos Dados

Arthur Henrique Cavalcante Rosa

2026-09-06

Contents

1	Carga e Visão Geral dos Dados	1
2	Verificação de Nulos	1
3	Taxa de Inadimplência por Safra (issue_d)	3
4	Análise Descritiva por Grupo de Variáveis	3
4.1	Capacidade Financeira e Renda (Affordability)	4
4.2	Score e Pontuação de Birô	5
4.3	Informações cadastrais	9
5	Análise de Correlação das Variáveis	10
6	Análise do Information Value	12
7	Análise da Cardinalidade da Variável Emp_Title	14

1 Carga e Visão Geral dos Dados

```
# Carregamento do dataset
dados <- read_csv2("../data/raw/concessoes_cp.csv")

# Shape dos dados
cat("Linhas:", nrow(dados), "| Colunas:", ncol(dados), "\n\n")

## Linhas: 29309 | Colunas: 43
```

2 Verificação de Nulos


```
# Tabela de dados faltantes (apenas variáveis com pelo menos 1 NA)
df_na <- dados |>
  summarise(across(everything(), ~ sum(is.na(.)))) |>
  pivot_longer(everything(), names_to = "variavel", values_to = "n_na") |>
  mutate(pct_na = (n_na / nrow(dados)) * 100) |>
  filter(n_na > 0) |>
  arrange(desc(pct_na))

# Gráfico de barras horizontais ordenado por severidade de NAs
ggplot(df_na, aes(x = pct_na, y = reorder(variavel, pct_na))) +
```

```

geom_col(fill = "#e74c3c", width = 0.7) +
geom_text(
  aes(label = paste0(round(pct_na, 1), "% (" , scales::comma(n_na), ")")),
  hjust = -0.1,
  size = 3.2,
  color = "black"
) +
scale_x_continuous(
  limits = c(0, 115),
  breaks = seq(0, 100, 20),
  labels = function(x) paste0(x, "%")
) +
labs(
  title = "Incidência de Valores Ausentes por Variável",
  subtitle = "Apenas variáveis com ausência superior a zero",
  x = "Percentual de Valores Ausentes (%)",
  y = NULL
) +
theme_minimal() +
theme(
  panel.grid.minor = element_blank(),
  panel.grid.major.y = element_blank(),
  axis.text.y = element_text(size = 9, face = "bold")
)

```




3 Taxa de Inadimplência por Safra (issue_d)

Acompanhamos a estabilidade do produto ao longo dos meses de 2016.

```
safra_resumo <- dados |>
  group_by(issue_d) |>
  summarise(
    contratos = n(),
    inadimplentes = sum(fl_default == 1, na.rm = TRUE),
    default_rate = round(inadimplentes / contratos * 100, 2)
  )

ggplot(safra_resumo, aes(x = issue_d, y = default_rate, group = 1)) +
  geom_line(color = "#2c3e50", size = 1) +
  geom_point(color = "#e74c3c", size = 3) +
  geom_text(aes(label = paste0(default_rate, "%")), vjust = -1, size = 3) +
  labs(
    title = "Evolução da inadimplência por Safra",
    x = "Safra",
    y = "Inadimplência (%)"
  ) +
  theme_minimal()
```



Note that the `echo = FALSE` parameter was added to the code chunk to prevent printing of the R code that generated the plot.

4 Análise Descritiva por Grupo de Variáveis

```
vars_capacidade <- c(
  "annual_inc",
  "verification_status",
  "dti",
  "loan_amnt",
  "int_rate"
)
```

```

vars_score <- c(
  "fico_range_low",
  "fico_range_high"
)

vars_inadimplencia <- c(
  "delinq_2yrs",
  "num_tl_30dpd",
  "num_tl_90g_dpd_24m",
  "acc_now_delinq",
  "delinq_amnt",
  "mths_since_recent_bc_dlq"
)

vars_alavancagem_birô <- c(
  "earliest_cr_line",
  "mo_sin_old_rev_tl_op",
  "mo_sin_old_il_acct",
  "mo_sin_rcnt_tl",
  "mths_since_recent_bc",
  "inq_last_12m",
  "acc_open_past_24mths",
  "num_tl_op_past_12m",
  "num_bc_tl",
  "num_actv_bc_tl",
  "revol_bal",
  "tot_cur_bal"
)

vars_cadastrais <- c(
  "emp_length",
  "home_ownership",
  "purpose",
  "addr_state",
  "application_type"
)

grupos_eda <- list(
  capacidade = vars_capacidade,
  score = vars_score,
  inadimplencia = vars_inadimplencia,
  alavancagem = vars_alavancagem_birô,
  cadastrais = vars_cadastrais
)

```

4.1 Capacidade Financeira e Renda (Affordability)

```

library(tidyverse)

# Remove colunas com nomes vazios ou espaços
dados_clean <- dados[, names(dados) != "" & !is.na(names(dados))]


dados_clean |>

```

```

select(fl_default, any_of(vars_capacidade)) |>
select(where(is.numeric)) |>
mutate(fl_default = as.factor(fl_default)) |>
pivot_longer(-fl_default, names_to = "variavel", values_to = "valor") |>
ggplot(aes(x = fl_default, y = valor, fill = fl_default)) +
geom_boxplot(outlier.alpha = 0.2) +
facet_wrap(~ variavel, scales = "free_y", ncol = 2) +
labs(x = "Default (0 = Não, 1 = Sim)", y = NULL) +
theme_minimal() +
theme(legend.position = "none")

```




4.2 Score e Pontuação de Birô

```

library(tidyverse)

dados_clean |>
select(fl_default, any_of(vars_score)) |>
select(where(is.numeric)) |>
mutate(fl_default = as.factor(fl_default)) |>
pivot_longer(-fl_default, names_to = "variavel", values_to = "valor") |>
ggplot(aes(x = fl_default, y = valor, fill = fl_default)) +
geom_boxplot(outlier.alpha = 0.2) +
facet_wrap(~ variavel, scales = "free_y", ncol = 2) +
labs(x = "Default (0 = Não, 1 = Sim)", y = NULL) +
theme_minimal() +
theme(legend.position = "none")

```



Histórico de Inadimplência

```
library(tidyverse)
```

```
dados_clean |>
```

```
  select(fl_default, any_of(vars_inadimplencia)) |>
```

```
  select(where(is.numeric)) |>
```

```
  mutate(fl_default = as.factor(fl_default)) |>
```

```
  pivot_longer(-fl_default, names_to = "variavel", values_to = "valor") |>
```

```
  ggplot(aes(x = fl_default, y = valor, fill = fl_default)) +
```


```
  geom_boxplot(outlier.alpha = 0.2) +
```

```
  facet_wrap(~ variavel, scales = "free_y", ncol = 3) +
```

```
  labs(x = "Default (0 = Não, 1 = Sim)", y = NULL) +
```

```
  theme_minimal() +
```


```
  theme(legend.position = "none")
```



Maturidade e Apetite por Crédito


```
library(tidyverse)
```

```
dados_clean |>
  select(fl_default, any_of(vars_alavancagem_birô)) |>
  select(where(is.numeric)) |>
  mutate(fl_default = as.factor(fl_default)) |>
  pivot_longer(-fl_default, names_to = "variavel", values_to = "valor") |>
  ggplot(aes(x = fl_default, y = valor, fill = fl_default)) +
  geom_boxplot(outlier.alpha = 0.2) +
  facet_wrap(~ variavel, scales = "free_y", ncol = 3) +
  labs(x = "Default (0 = Não, 1 = Sim)", y = NULL) +
  theme_minimal() +
  theme(legend.position = "none")
```



```
library(tidyverse)


dados_clean |>
  select(fl_default, dti) |>
  filter(!is.na(dti), dti >= 0, dti <= 100) |>
  mutate(fl_default = factor(fl_default, levels = c(0, 1), labels = c("Não Default", "Default"))) |>
  ggplot(aes(x = fl_default, y = dti, fill = fl_default)) +
  geom_boxplot(outlier.alpha = 0.15, width = 0.5) +
  labs(
    x = NULL,
    y = "DTI (%)"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```

4.3 Informações cadastrais

```
library(tidyverse)

dados_clean |>
  select(fl_default, any_of(vars_cadastrais)) |>
  select(fl_default, where(~ is.character(.) || is.factor(.))) |>
  pivot_longer(-fl_default, names_to = "variavel", values_to = "categoria") |>
  filter(!is.na(categoria)) |>
  group_by(variavel, categoria) |>
  summarise(
    total = n(),
    taxa_inadimplencia = mean(fl_default == 1, na.rm = TRUE),
    .groups = "drop"
  ) |>
  filter(total >= 30) |>
  ggplot(aes(x = reorder(categoria, taxa_inadimplencia), y = taxa_inadimplencia)) +
  geom_col(fill = "#e74c3c", width = 0.7) +
  coord_flip() +
  facet_wrap(~ variavel, scales = "free_y", ncol = 2) +
  scale_y_continuous(labels = scales::percent_format(accuracy = 1)) +
  labs(x = NULL, y = "Taxa de Inadimplência (%)") +
  theme_minimal()
```



5 Análise de Correlação das Variáveis

```
library(tidyverse)

dados_corr <- dados_clean |>
  select(where(is.numeric)) |>
  select(-any_of(c("id", "member_id", "fl_default", "last_pymnt_amnt", "hardship_length")))

matriz_corr <- cor(dados_corr, use = "pairwise.complete.obs", method = "spearman")

matriz_corr[upper.tri(matriz_corr)] <- NA


df_corr <- as.data.frame(matriz_corr) |>
  rownames_to_column(var = "var1") |>
  pivot_longer(-var1, names_to = "var2", values_to = "correlacao") |>
  filter(!is.na(correlacao))

ggplot(df_corr, aes(x = var1, y = var2, fill = correlacao)) +
  geom_tile(color = "white") +
  geom_text(
```

```

aes(label = sprintf("%.2f", correlacao)),
color = "black",
size = 2.4
) +
scale_fill_gradient2(
low = "#e74c3c",
mid = "#ffffff",
high = "#2980b9",
midpoint = 0,
limit = c(-1, 1),
name = "Spearman"
) +
theme_minimal() +
theme(
axis.text.x = element_text(angle = 45, vjust = 1, hjust = 1, size = 8),
axis.text.y = element_text(size = 8),
axis.title = element_blank(),
panel.grid = element_blank()
)

```



6 Análise do Information Value

```
library(tidyverse)
library(scorecard)

# 1. Seleciona apenas as variáveis preditoras candidatas e o alvo
df_iv <- dados_clean |>
  select(-any_of(c("id", "member_id", "issue_d", "last_pymnt_amnt",
                  "hardship_flag", "hardship_length", "dti_joint",
                  "sec_app_earliest_cr_line", "zip_code", "emp_title")))


# 2. Calcula o Information Value para todas as variáveis
```

```

iv_resultado <- scorecard::iv(df_iv, y = "fl_default")

# 3. Adiciona interpretação de negócio e plota o ranking
iv_resultado |>
  as_tibble() |>
  mutate(
    poder_preditivo = case_when(
      info_value < 0.02 ~ "Inútil (< 0.02)",
      info_value < 0.10 ~ "Fraco (0.02 - 0.10)",
      info_value < 0.30 ~ "Médio (0.10 - 0.30)",
      info_value < 0.50 ~ "Forte (0.30 - 0.50)",
      TRUE ~ "Suspeito / Muito Forte (> 0.50)"
    ),
    poder_preditivo = factor(poder_preditivo, levels = c(
      "Inútil (< 0.02)", "Fraco (0.02 - 0.10)", "Médio (0.10 - 0.30)",
      "Forte (0.30 - 0.50)", "Suspeito / Muito Forte (> 0.50)"
    ))
  ) |>
  ggplot(aes(x = reorder(variable, info_value), y = info_value, fill = poder_preditivo)) +
  geom_col(width = 0.7) +
  coord_flip() +
  scale_fill_manual(values = c(
    "Inútil (< 0.02)" = "#bdc3c7",
    "Fraco (0.02 - 0.10)" = "#f39c12",
    "Médio (0.10 - 0.30)" = "#2980b9",
    "Forte (0.30 - 0.50)" = "#27ae60",
    "Suspeito / Muito Forte (> 0.50)" = "#e74c3c"
  )) +
  labs(
    title = "Ranking de Poder Preditivo (Information Value)",
    x = "Variável",
    y = "Information Value (IV)",
    fill = "Poder Preditivo"
  ) +
  theme_minimal()

```



7 Análise da Cardinalidade da Variável Emp_Title

```
library(tidyverse)

# Tabela com a quantidade e percentual de singletons
singletons_resumo <- dados |>
  filter(!is.na(emp_title)) |>
  count(emp_title) |>
  summarise(
    total_cargos_distintos = n(),
    total_singletons = sum(n == 1),
    pct_singletons = mean(n == 1)
  )

print(singletons_resumo)
```

```
## # A tibble: 1 x 3
##   total_cargos_distintos total_singletons pct_singletons
##               <int>           <int>         <dbl>
## 1             12748             10527         0.826
```

```
# Exibe os primeiros 20 cargos que aparecem exatamente 1 vez na base inteira
dados |>
```

```
  filter(!is.na(emp_title)) |>
  count(emp_title) |>
  filter(n == 1) |>
  select(emp_title, contagem = n) |>
  slice_head(n = 20) |>
  print(n = 20)
```

```
## # A tibble: 20 x 2
##   emp_title                contagem
##   <chr>                  <int>
## 1 (Faculty) Program Lead          1
## 2 (Finance) Account's Receivable Ckerk 1
## 3 1 on 1 Aide                    1
## 4 13 F                          1
## 5 14 t                          1
## 6 1st Grade Teacher              1
## 7 1st Line Supervisor            1
## 8 1st grade teacher              1
## 9 1st press operator              1
## 10 1st pressman                  1
## 11 2FOX1                        1
## 12 2nd Grade Teacher             1
## 13 2nd Mate                     1
## 14 2nd asst mgr                  1
## 15 3rd Shift Supervisor          1
## 16 3rd shift lead plant operator 1
## 17 4                            1
## 18 4th gr. Teacher              1
## 19 4th manager                  1
## 20 5 years                      1
```

```
# Top 10 cargos mais comuns vs tamanho da base
dados |>
```

```
  filter(!is.na(emp_title)) |>
  count(emp_title, sort = TRUE) |>
  mutate(
    pct = n / sum(n),
    pct_acumulado = cumsum(pct)
  ) |>
  slice_head(n = 10)
```

```
## # A tibble: 10 x 4
##   emp_title      n    pct pct_acumulado
##   <chr>    <int> <dbl>      <dbl>
## 1 Teacher    587 0.0215      0.0215
## 2 Manager    495 0.0181      0.0395
## 3 Owner      302 0.0110      0.0506
## 4 Supervisor 254 0.00928     0.0599
## 5 RN         239 0.00874     0.0686
## 6 Sales       238 0.00870     0.0773
## 7 Registered Nurse 228 0.00833     0.0856
## 8 Driver      220 0.00804     0.0937
## 9 Project Manager 162 0.00592     0.0996
```

## 10 Director	159 0.00581	0.105
----------------	-------------	-------