

Preparação dos Dados e Criação de Feature Stores

Arthur Henrique Cavalcante Rosa

2026-09-06

Contents

1	Exclusão de Variáveis	1
1.1	Vazamento Temporal (Data Leakage)	1
1.2	Excesso de Nulos ou Alta Cardinalidade	1
1.3	Ruído Estatístico (Information Value < 0.02)	2
2	Nova Verificação da Qualidade dos Dados	3
3	Tratamento de Dados Nulos	3
4	Tratamento de Multicolinearidade	4
4.1	Variáveis Numéricas	4
4.2	Variáveis Categóricas	4
5	Tratamento de Outliers	5
6	Tratamento de Variáveis Categóricas	6
7	Salvamento das Feature Stores	7

```
# Carregamento do dataset
dados <- read_csv2("../data/raw/concessoes_cp.csv")
```

1 Exclusão de Variáveis

1.1 Vazamento Temporal (Data Leakage)

```
vars_drop_leakage <- c(
  "last_pymnt_amnt", "hardship_flag", "hardship_length"
)

dados <- dados |>
  select(-any_of(vars_drop_leakage))
```

1.2 Excesso de Nulos ou Alta Cardinalidade

```
vars_drop_qualidade <- c(
  "dti_joint", "sec_app_earliest_cr_line", "member_id",
  "mths_since_recent_bc_dlq", "emp_title", "zip_code"
)
```

```
dados <- dados |>
  select(-any_of(vars_drop_qualidade))
```

1.3 Ruído Estatístico (Information Value < 0.02)

```
vars_drop_iv <- c(
  "emp_length",
  "num_actv_bc_tl",
  "delinq_amnt",
  "purpose",
  "num_bc_tl",
  "delinq_2yrs",
  "num_tl_90g_dpd_24m",
  "acc_now_delinq",
  "application_type",
  "...1",          # Índice da leitura do CSV
  "num_tl_30dpd"
)
```

```
dados <- dados |>
  select(-any_of(vars_drop_iv))
```

```
# 1. Quantidade total de colunas restantes
ncol(dados)
```

```
## [1] 23
```

```
# 2. Lista completa com nome e tipo de cada variável
glimpse(dados)
```

```
## Rows: 29,309
## Columns: 23
## $ addr_state      <chr> "CA", "TN", "UT", "TX", "FL", "NE", "FL", "GA~
## $ home_ownership  <chr> "MORTGAGE", "MORTGAGE", "MORTGAGE", "RENT", "~
## $ verification_status...7 <chr> "Source Verified", "Not Verified", "Verified"~
## $ dti             <dbl> 16.61, 22.81, 27.17, 6.34, 17.21, 13.40, 34.2~
## $ earliest_cr_line <chr> "Mar-2005", "Nov-1997", "Jul-2004", "Mar-2007~
## $ fico_range_high  <dbl> 714, 734, 704, 699, 674, 724, 664, 744, 694, ~
## $ fico_range_low   <dbl> 710, 730, 700, 695, 670, 720, 660, 740, 690, ~
## $ id              <dbl> 88915767, 70953843, 71955065, 68704932, 84657~
## $ inq_last_12m     <dbl> 3, 1, 2, 7, 2, 2, 4, 2, 7, 1, 2, 0, 3, 0, 0, ~
## $ int_rate         <dbl> 19.99, 9.16, 21.18, 14.85, 15.59, 7.39, 25.69~
## $ issue_d          <date> 2016-09-01, 2016-02-01, 2016-02-01, 2016-01~
## $ loan_amnt        <dbl> 24000, 28000, 29400, 6000, 20000, 21000, 2122~
## $ fl_default       <dbl> 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, ~
## $ tot_cur_bal      <dbl> 455841, 237578, 167941, 9870, 295345, 319081,~
## $ annual_inc       <dbl> 70000.00, 105000.00, 30000.00, 56000.00, 7000~
## $ revol_bal        <dbl> 7292, 27519, 19170, 519, 15496, 18770, 15302,~
## $ mo_sin_old_rev_tl_op <dbl> 137, 219, 87, 106, 102, 320, 349, 19, 289, 74~
## $ acc_open_past_24mths <dbl> 9, 4, 7, 2, 8, 4, 7, 2, 12, 10, 4, 3, 3, 3, 1~
## $ mo_sin_old_il_acct <dbl> 136, 174, 139, 88, 100, 147, 157, 90, 162, 11~
## $ mo_sin_rcnt_tl    <dbl> 4, 4, 1, 8, 3, 5, 1, 1, 2, 3, 4, 5, 3, 10, 10~
## $ mths_since_recent_bc <dbl> 10, 4, 71, 24, 16, 8, 8, 19, 4, 10, 15, 56, 1~
## $ num_tl_op_past_12m <dbl> 2, 2, 6, 1, 4, 4, 3, 1, 6, 5, 2, 1, 1, 1, 1, ~
```

```
## $ verification_status...39 <chr> "Source Verified", "Not Verified", "Verified"~
```

2 Nova Verificação da Qualidade dos Dados

```
library(tidyverse)

# Tabela com contagem e percentual de nulos ordenada do maior para o menor
dados |>
  summarise(across(everything(), ~ sum(is.na(.)))) |>
  pivot_longer(everything(), names_to = "variavel", values_to = "total_na") |>
  mutate(
    total_linhas = nrow(dados),
    pct_na = round((total_na / total_linhas) * 100, 2)
  ) |>
  arrange(desc(total_na)) |>
  print(n = Inf)
```

```
## # A tibble: 23 x 4
##   variavel      total_na total_linhas pct_na
##   <chr>          <int>      <int>  <dbl>
## 1 mo_sin_old_il_acct      756      29309  2.58
## 2 mths_since_recent_bc    321      29309  1.1
## 3 inq_last_12m           4      29309  0.01
## 4 dti                    3      29309  0.01
## 5 addr_state              0      29309  0
## 6 home_ownership          0      29309  0
## 7 verification_status...7 0      29309  0
## 8 earliest_cr_line        0      29309  0
## 9 fico_range_high         0      29309  0
## 10 fico_range_low         0      29309  0
## 11 id                     0      29309  0
## 12 int_rate               0      29309  0
## 13 issue_d                0      29309  0
## 14 loan_amnt              0      29309  0
## 15 fl_default             0      29309  0
## 16 tot_cur_bal            0      29309  0
## 17 annual_inc             0      29309  0
## 18 revol_bal              0      29309  0
## 19 mo_sin_old_rev_tl_op    0      29309  0
## 20 acc_open_past_24mths    0      29309  0
## 21 mo_sin_rcnt_tl         0      29309  0
## 22 num_tl_op_past_12m      0      29309  0
## 23 verification_status...39 0      29309  0
```

3 Tratamento de Dados Nulos

Trata os casos nulos utilizando a mediana da respectiva variável, considerando apenas dados da safra atual do registro nulo para o calculo da mediana.

```
library(tidyverse)
vars_imputar <- c("dti", "inq_last_12m", "mths_since_recent_bc", "mo_sin_old_il_acct")

dados <- dados |>
```

```

group_by(issue_d) |>
mutate(
  across(
    all_of(vars_imputar),
    ~ if_else(is.na(.), median(., na.rm = TRUE), .)
  )
) |>
ungroup() |>
# Fallback: caso alguma safra inteira tenha ficado sem mediana (100% NAs)
mutate(
  across(
    all_of(vars_imputar),
    ~ if_else(is.na(.), median(., na.rm = TRUE), .)
  )
)

# Checagem se zerou os nulos dessas 4 variáveis
dados |>
  summarise(across(all_of(vars_imputar), ~ sum(is.na(.))))

## # A tibble: 1 x 4
##   dti inq_last_12m mths_since_recent_bc mo_sin_old_il_acct
##   <int>      <int>          <int>          <int>
## 1      0          0              0              0

```

4 Tratamento de Multicolinearidade

4.1 Variáveis Numéricas

Dois pares de variáveis se mostraram altamente correlacionados, são eles: 1. fico_range_low e fico_range_high: com uma correlação de 1.0, vou criar um score unico para os dados de fico que será a média das duas variáveis. 2. num_tl_op_past_12m e acc_open_past_24mths: com uma correlação de 0.76, nesse caso vou manter a variável acc_open_past_24mths pois ela tem um information value maior. 3. A variável earliest_cr_line apensar de ser categórica já é representada pela acc_open_past_24mths logo também será retirada.

```

dados <- dados |>
mutate(
  # Cria o score central e remove as duas colunas redundantes
  fico_score = (fico_range_low + fico_range_high) / 2
) |>
select(-fico_range_low, -fico_range_high)

# Mantém a de maior IV: acc_open_past_24mths
dados <- dados |>
select(-num_tl_op_past_12m, -earliest_cr_line)

```

4.2 Variáveis Categóricas

```

# Verifica se os valores são 100% iguais linha a linha
prop_iguais <- mean(dados[["verification_status...7"]] == dados[["verification_status...39"]], na.rm = TRUE)
total_na_7 <- sum(is.na(dados[["verification_status...7"]]))
total_na_39 <- sum(is.na(dados[["verification_status...39"]]))

```

```
tibble(
  proporcao_iguais = prop_iguais,
  nulcol_7 = total_na_7,
  nulcol_39 = total_na_39
)

## # A tibble: 1 x 3
##   proporcao_iguais nulcol_7 nulcol_39
##           <dbl>      <int>      <int>
## 1             1          0          0
```

Como a proporção bateu 100% entendo que as variáveis possuem os mesmos dados, logo ficamos apenas com uma que foi renomeada para `verification_status`.

```
dados <- dados |>
  rename(verification_status = `verification_status...7`) |>
  select(-`verification_status...39`)
```

5 Tratamento de Outliers

Para fazer o tratamento de outliers e evitar um possível data leakage vou dividir os dados de treino e teste antes do tratamento:

```
dados_treino <- dados |>
  filter(month(issue_d) >= 1 & month(issue_d) <= 9)

dados_teste <- dados |>
  filter(month(issue_d) >= 10 & month(issue_d) <= 12)

# Validação do volume em cada partição
cat("Linhas Treino (Jan-Set):", nrow(dados_treino), "\n")
```

```
## Linhas Treino (Jan-Set): 23614

cat("Linhas Teste (Out-Dez):", nrow(dados_teste), "\n")
```

```
## Linhas Teste (Out-Dez): 5695
```

Capping superior (Winsorization a 99%): trava valores extremos no percentil 99 calculado no treino, evitando distorções por outliers sem descartar registros.

```
glimpse(dados)
```

```
vars_continuas <- c(
  "dti", "inq_last_12m", "int_rate", "loan_amnt", "tot_cur_bal", "annual_inc", "revol_bal", "mo_sin_old"
)

vars_categoricas <- c(
  "addr_state", "verification_status", "home_ownership"
)

# Calcula o percentil 99 EXCLUSIVAMENTE nos dados de treino
limites_p99 <- dados_treino |>
  summarise(across(all_of(vars_continuas), ~ quantile(., 0.99, na.rm = TRUE)))

# Função para aplicar as réguas de corte calculadas no treino
aplica_capping <- function(df, limites) {
```

```

for (col in names(limites)) {
  teto <- limites[[col]][[1]]
  df[[col]] <- if_else(df[[col]] > teto, teto, df[[col]])
}
df
}

# Aplica os limites calculados no treino tanto no treino quanto no teste
dados_treino <- aplica_capping(dados_treino, limites_p99)
dados_teste <- aplica_capping(dados_teste, limites_p99)

```

6 Tratamento de Variáveis Categóricas

Para conseguir usar as variáveis categóricas é necessário transformá-las em variáveis numéricas, nesse cenário vou usar uma abordagem híbrida. Para variáveis que possuem baixa cardinalidade (home_ownership, verification_status) vou usar o One-Hot Encoding. Já para variáveis que tem alta cardinalidade, ou seja, muitas categorias, vou optar pelo Target Encoding que substitui cada categoria pela taxa média histórica de inadimplência, condensando dezenas de níveis em uma única coluna contínua sem explodir a dimensionalidade com dezenas de dummies esparsas.

```

library(tidyverse)

# Lista variáveis categóricas e conta os níveis únicos no treino
resumo_categoricas <- dados_treino |>
  select(where(~ is.character(.) || is.factor(.))) |>
  summarise(across(everything(), ~ n_distinct(.))) |>
  pivot_longer(everything(), names_to = "variavel", values_to = "n_niveis") |>
  arrange(desc(n_niveis))

print(resumo_categoricas)

## # A tibble: 3 x 2
##   variavel      n_niveis
##   <chr>         <int>
## 1 addr_state      50
## 2 home_ownership    3
## 3 verification_status 3

library(tidyverse)
library(fastDummies)

# Target Encoding para addr_state (calculado estritamente no treino)
media_global <- mean(dados_treino$fl_default)

mapa_estado <- dados_treino |>
  group_by(addr_state) |>
  summarise(
    n = n(),
    addr_state_encoded = (sum(fl_default) + 10 * media_global) / (n + 10),
    .groups = "drop"
  ) |>
  select(addr_state, addr_state_encoded)

# Aplica o encoding no Treino e no Teste

```

```

dados_treino <- dados_treino |>
  left_join(mapa_estado, by = "addr_state") |>
  mutate(addr_state_encoded = coalesce(addr_state_encoded, media_global)) |>
  select(-addr_state)

dados_teste <- dados_teste |>
  left_join(mapa_estado, by = "addr_state") |>
  mutate(addr_state_encoded = coalesce(addr_state_encoded, media_global)) |>
  select(-addr_state)

# One-Hot Encoding para home_ownership e verification_status
vars_dummies <- c("home_ownership", "verification_status")

dados_treino <- dummy_cols(
  dados_treino,
  select_columns = vars_dummies,
  remove_first_dummy = TRUE,
  remove_selected_columns = TRUE
)

dados_teste <- dummy_cols(
  dados_teste,
  select_columns = vars_dummies,
  remove_first_dummy = TRUE,
  remove_selected_columns = TRUE
)

# Alinhamento de colunas (garante idêntica ordem e estrutura nas duas bases)
dados_teste <- dados_teste |> select(all_of(names(dados_treino)))

```

7 Salvamento das Feature Stores

```

library(readr)

# 1. Exporta em CSV (legível e universal)
write_csv(dados_treino, "../data/trusted/feature_store_treino.csv")
write_csv(dados_teste, "../data/trusted/feature_store_inferencia.csv")

# Confirmação do tamanho das bases salvas
cat("Treino salvo:", nrow(dados_treino), "linhas e", ncol(dados_treino), "colunas.\n")

## Treino salvo: 23614 linhas e 21 colunas.
cat("Inferência salva:", nrow(dados_teste), "linhas e", ncol(dados_teste), "colunas.\n")

## Inferência salva: 5695 linhas e 21 colunas.

```