

Modelo de Propensão à Inadimplência

Arthur Henrique Cavalcante Rosa

Motivação Estratégica

Substituição de políticas baseadas em regras heurísticas por inteligência quantitativa

Cenário Atual (Regras Fixas)

- Decisões pautadas em réguas determinísticas manuais.
- Falta de calibração entre taxa de juros, limites e risco real.
- Gargalo operacional que trava a escalabilidade da fintech.

Objetivo da Modelagem

- **Substituição de Heurísticas:** Modelo de score estatístico preciso e escalável para substituir regras fixas.
- **Esteira de Aprovação:** Estimar a probabilidade de inadimplência para definir quem será aprovado ou recusado.
- **Risk-Based Pricing:** Fornecer insumo quantitativo para determinar a taxa de empréstimo conforme o risco real.

Carteira Analisada

- 29.309 operações de crédito ao longo de 2016.
- Taxa de inadimplência média da carteira em torno de 23,5%.
- Forte sazonalidade com aceleração de default no segundo semestre.

Highlights da Análise Exploratória (EDA)

Diagnóstico estrutural, correlação multivariada e identificação de anomalias

Diagnóstico Visual de Outliers:

Boxplots revelaram assimetria severa e valores extremos em variáveis de capacidade e alavancagem (annual_inc, dti, revol_bal e inq_last_12m), exigindo tratamento.

Matriz de Correlação de Spearman:



Identificação de fortes redundâncias: colinearidade perfeita entre réguas de birô (fico_low e high com rho=1.0) e alta correlação entre linhas de crédito (rho=0.76).

Triagem por Information Value (IV):

Separação de preditores robustos (int_rate, dti, annual_inc) frente a atributos de ruído estatístico para inadimplência (IV < 0.02).

Alta Dispersão em Ocupação (emp_title):

Dos 12.748 cargos distintos, 82,6% eram singletons (apareciam apenas 1 vez), sinalizando descarte para mitigar sobreajuste.



Highlights de Pré-processamento

Partição Out-of-Time

- Divisão temporal simulando ambiente produtivo real.
- Treino: Jan a Set/2016 (23.614 propostas).
- Teste OOT: Out a Dez/2016 (5.695 propostas).
- Garante que o modelo avalie comportamentos puramente futuros.

Tratamento de Variáveis Numéricas

- Imputação pela mediana calculada dentro de cada safra.
- Capping superior no percentil 99 obtido no treino (sem descarte).
- Unificação do FICO score (média low/high por correlação = 1.0).
- Eliminação de duplicidades e multicolinearidades fortes.

Tratamento de Variáveis Categóricas

- Target Encoding em addr_state: condensa 50 estados em 1 vetor contínuo com suavização bayesiana.
- One-Hot Encoding nas variáveis de baixa cardinalidade (propriedade do imóvel e verificação de renda).

Algoritmo Adotado: Regressão Logística

Interpretabilidade e Sentido Econômico

Cada variável possui um coeficiente (beta) direto e mensurável.
É possível auditar com precisão o peso das variáveis eliminando o risco de 'caixa-preta' perante conselhos e comitês de risco.

Monotonicidade e Prevenção de Arbitrariedades

Garante que variações lógicas em fatores determinantes reduzam a inadimplência de forma suave e contínua, sem saltos abruptos.

Padrão de Conformidade

Metodologia consolidada de referência em risco bancário, facilitando aprovações em auditorias internas, validações de esteira e exigências regulatórias.

Coeficientes Estatísticos

Todos os regressores finais apresentaram significância estatística (p-valor < 0,05)

Variável Preditora	Estimador (Beta)	Z-Value	Direcionamento Econômico
fico_score	-0.0066	-10.01	Proteção: maior pontuação de histórico financeiro reduz drasticamente a chance de default.
dti	+0.0129	5.99	Alavancagem: maior comprometimento sobrecarrega a capacidade de pagamento do tomador.
loan_amnt	+0.00002	10.19	Tíquete: volumes solicitados mais altos ampliam a inadimplência esperada.
annual_inc	-0.000002	-4.33	Capacidade: rendas maiores amortecem choques financeiros e diminuem o risco.
acc_open_past_24mths	+0.0449	7.35	Apetite: abertura acelerada de novas contas indica estresse recente de liquidez.

Validação Out-of-Time

Resultados comprovados no conjunto de teste de Outubro a Dezembro


AUC-ROC: 0,7036

Comprova sólida capacidade de discriminação ordinal para crédito pessoal descolateralizado. O modelo acerta a ordenação relativa de risco entre um cliente adimplente e um inadimplente em mais de 70% das combinações possíveis.

KS (Kolmogorov-Smirnov): 30,65%

O ponto de máxima separação estatística entre as curvas acumuladas de adimplentes e inadimplentes ocorre no score predito de 0,216.

A dispersão do AUC-ROC ao longo do trimestre de teste foi inferior a 0,01, o que demonstra ausência de sobreajuste temporal e garante confiabilidade para implantação em produção contínua.



Segmentação de Ratings

Otimização via Arvore de Decisão para encontrar as quebras com máxima pureza estatística.

Rating	Perfil de Risco	Volume	% Base	Faixa de Probabilidade	Taxa Real de Default
A	Risco Mínimo	461	8,1%	0,0177 a 0,0786	4,1%
B	Risco Baixo	975	17,1%	0,0787 a 0,1360	10,5%
C	Risco Médio	1.431	25,1%	0,1360 a 0,2160	17,2%
D	Risco Alto	1.721	30,2%	0,2160 a 0,3680	28,2%
E	Risco Crítico	1.107	19,4%	0,3680 a 0,7810	45,7%

Destaques da Segmentação via Árvore

- Monotonicidade: Risco sobe estritamente de 4,1% para 45,7%, validando a ordenação das faixas.
- Separação de Cauda: O Rating E concentra quase metade dos default da carteira em menos de 20% das propostas.

Direcionais de Negócio por Rating

Rating	Decisão de Esteira	Política de Limites
A (~4% def)	Aprovação Automática	Limites máximos pré-aprovados e flexibilidade de prazo.
B (~10% def)	Aprovação Automática	Limite pleno compatível com a renda comprovada.
C (~17% def)	Aprovação Condicionada	Limite moderado de entrada com aumento progressivo via histórico.
D (~28% def)	Mesa Manual / Restritiva	Limite mínimo restritivo com prazos reduzidos de liquidação.
E (~45% def)	Recusa Automática	Inviável economicamente. Oferta direcionada a produtos garantidos.

Próximos Passos

Implantação em Produção

Integração via API de Decisão: Empacotar o pipeline de pré-processamento e o modelo serializado para consumo em tempo real pelo motor de crédito no momento do preenchimento da proposta.

Automação das Esteiras A e E: Configurar aprovação imediata sem fricção para o Rating A e bloqueio automático de propostas sem garantia para o Rating E.

Monitoramento Contínuo

Acompanhamento de Drift e Estabilidade: Criar dashboards automatizados para rastrear desvios na distribuição dos dados de entrada e oscilações no *score* ao longo das novas safras.

Observabilidade de Performance: Recalcular periodicamente as métricas de ordenação (AUC-ROC e KS) e a calibração da taxa de inadimplência observada contra a esperada em cada faixa de *rating*.